



从零开始手写VIO_第六期

第4章作业思路分享

基于滑动窗口算法的VIO 系统


可观性和一致性



0. 作业内容

作业


- ① 某时刻，SLAM 系统中相机和路标点的观测关系如下图所示，其中 ξ 表示相机姿态， L 表示观测到的路标点。当路标点 L 表示在世界坐标系下时，第 k 个路标被第 i 时刻的相机观测到，重投影误差为 $r(\xi_i, L_k)$ 。另外，相邻相机之间存在运动约束，如 IMU 或者轮速计等约束。



- 1 请绘制上述系统的信息矩阵 Λ .
 - 2 请绘制相机 ξ_1 被 marg 以后的信息矩阵 Λ' .
- ② 阅读《Relationship between the Hessian and Covariance Matrix for Gaussian Random Variables》. 证明信息矩阵和协方差的逆之间的关系。
- ③ 请补充作业代码中单目 Bundle Adjustment 信息矩阵的计算，并输出正确的结果。正确的结果为：奇异值最后 7 维接近于 0，表明零空间的维度为 7.

1. 信息矩阵与边缘化

1.1



	ξ_1	ξ_2	ξ_3	L_1	L_2	L_3
ξ_1						
ξ_2						
ξ_3						
L_1						
L_2						
L_3						

1. 信息矩阵与边缘化


1.2

	ξ_1	ξ_2	ξ_3	L_1	L_2	L_3
ξ_1	$\Lambda_{\beta\beta}$			$\Lambda_{\beta\alpha}$		
ξ_2						
ξ_3						
L_1	$\Lambda_{\alpha\beta}$			$\Lambda_{\alpha\alpha}$		
L_2						
L_3						

即有：

$$\Lambda_{\alpha\alpha} - \Lambda_{\alpha\beta} \Lambda_{\beta\beta}^{-1} \Lambda_{\beta\alpha}$$

$$\Lambda' = \Lambda_{\alpha\alpha} - \Lambda_{\alpha\beta} \Lambda_{\beta\beta}^{-1} \Lambda_{\beta\alpha} \quad (1)$$



	ξ_2	ξ_3	L_1	L_2	L_3
ξ_2					
ξ_3					
L_1					
L_2					
L_3					

1. 信息矩阵与边缘化

1.2


```
1 #include <iostream>
2 #include <Eigen/Core>
3 #include <Eigen/Dense>
4
5 int main(int argc, char **argv) {
6     Eigen::Matrix<double, 6, 6> matInfo_pre;
7     Eigen::Matrix<char, 6, 6> matInfo_pre_show;
8     matInfo_pre << 1, 1, 0, 1, 1, 0,
9                    1, 1, 1, 1, 1, 1,
10                   0, 1, 1, 0, 1, 1,
11                   1, 1, 0, 1, 0, 0,
12                   1, 1, 1, 0, 1, 0,
13                   0, 1, 1, 0, 0, 1;
14     for (int i = 0; i < matInfo_pre.rows(); ++i) {
15         for (int j = 0; j < matInfo_pre.cols(); ++j) {
16             if (matInfo_pre(i, j) == 0)
17                 matInfo_pre_show(i, j) = '0';
18             else
19                 matInfo_pre_show(i, j) = '#';
20         }
21     }
22     std::cout << "Previous information matrix before marginalization = \n" << matInfo_pre_show.matrix() << std::endl;
23
24     // marginalization parts
25     Eigen::Matrix<double, 5, 5> mat_aa = matInfo_pre.block<5, 5>(1, 1);
26     Eigen::Matrix<double, 1, 1> mat_bb = matInfo_pre.block<1, 1>(0, 0);
27     Eigen::Matrix<double, 5, 1> mat_ab = matInfo_pre.block<5, 1>(1, 0);
28     Eigen::Matrix<double, 1, 5> mat_ba = mat_ab.transpose();
29     Eigen::Matrix<double, 5, 5> mat_abbbba = mat_ab * mat_bb.inverse() * mat_ba;
30
31     Eigen::Matrix<double, 5, 5> matInfo_new = Eigen::Matrix<double, 5, 5>::Zero();
32     Eigen::Matrix<char, 5, 5> matInfo_new_show = Eigen::Matrix<char, 5, 5>::Zero();
33     for (int i = 0; i < matInfo_new.rows(); ++i) {
34         for (int j = 0; j < matInfo_new.cols(); ++j) {
35             if (mat_aa(i, j) != 0 || mat_abbbba(i, j) != 0) {
36                 matInfo_new(i, j) = 1.0;
37                 matInfo_new_show(i, j) = '#';
38             }
39             else {
40                 matInfo_new(i, j) = 0.0;
41                 matInfo_new_show(i, j) = '0';
42             }
43         }
44     }
45     std::cout << "\nNew information matrix after marginalization = \n" << matInfo_new_show.matrix() << std::endl;
46
47     return 0;
48 }
49
```

Previous information matrix before marginalization =

```
# # 0 # # 0
# # # # #
0 # # 0 # #
# # 0 # 0 0
# # # 0 # 0
0 # # 0 0 #
```

New information matrix after marginalization =

```
# # # # #
# # 0 # #
# 0 # # 0
# # # # 0
# # 0 0 #
```



2. 阅读论文与证明

对于多维 Gaussian 分布，其概率密度函数 (Probability Density Function, PDF) 如下式：

$$P(x) = \frac{1}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) \quad x \sim N(\mu, \Sigma)$$

因此对其求最大估计时等效于对其负对数求最小估计，亦即：

$$-\ln(P(x)) = \frac{1}{2} \ln((2\pi)^N \det(\Sigma)) + \frac{1}{2} (x-\mu)^T \Sigma^{-1}(x-\mu)$$

同时，目标函数（即原 Gaussian 分布负对数）的 Hessian 矩阵（亦即目标函数的信息矩阵）为：

$$H = H^{(l,l')}(\theta^*) = J^T J = \left. \frac{\partial^2 J(\theta)}{\partial \theta_l \partial \theta_{l'}} \right|_{\theta=\theta^*} = (\Sigma_\theta^{-1})^{(l,l')}$$

故有：以 Gaussian 分布负对数为目标函数的 Hessian 矩阵（信息矩阵）等于原 Gaussian 分布的协方差矩阵的逆，如下：

$$\mathcal{H}(\theta^*) = \Sigma_\theta^{-1}$$

此结论对于 Gaussian 分布是有效的，对于其他分布形式未必成立。而当 Gaussian 分布均值为状态的非线性函数时，可利用线性化将其展开近似为线性函数，同理可利用原 Gaussian 分布协方差矩阵的逆近似估计其负对数的 Hessian 矩阵（信息矩阵）。



3. nullspace_test

a. 残差对位姿的 Jacobian:

$$\frac{\partial e}{\partial \delta \xi} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{bmatrix}$$

b. 残差对路标点坐标的 Jacobian:

$$\frac{\partial e}{\partial \mathbf{P}} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix} \mathbf{R}$$



```
// information matrix (hessian matrix)
/// 请补充完整作业信息矩阵块的计算
H.block(i*6,i*6,6,6) += jacobian_Ti.transpose() * jacobian_Ti;
H.block(i*6, 6*poseNums + j*3, 6, 3) += jacobian_Ti.transpose() * jacobian_Pj;
H.block(6*poseNums + j*3, i*6, 3, 6) += jacobian_Pj.transpose() * jacobian_Ti;
H.block(6*poseNums + j*3, 6*poseNums + j*3, 3, 3) += jacobian_Pj.transpose() * jacobian_Pj;
```

```
0.00230246
0.00172459
0.000422374
3.21708e-17
2.06732e-17
1.43188e-17
7.66992e-18
6.08423e-18
6.05715e-18
3.94363e-18
```

7



深蓝学院
shenlanxueyuan.com

感谢各位聆听

Thanks for Listening

