



深蓝学院
shenlanxueyuan.com

从零手写VIO-第六期 大作业 思路讲解



主讲人 吴少腾



●更好的优化策略

- 选用更优的 LM 策略, 使得 VINS-Mono 在 MH-05 数据集上收敛速度更快或者精度更高.
- 实现 dog-leg 算法替换 LM 算法, 并测试替换后的 VINS-Mono 在 MH-05 上算法精度.

●更快的 MakeHessian

- 可以采用任何一种或多种加速方式 (如多线程, 如sse指令集等) 对信息矩阵的拼接函数加速, 并给出详细的实验对比报告.

更好的优化策略

●更优的LM策略

1. 算法退出条件（problem.cc中被注释的代码）：

- 限制步数；
- 残差阈值；
- $\|\delta_p\|$ 阈值；
- ...

2. 更换阻尼策略

...

Input: A vector function $f : \mathcal{R}^m \rightarrow \mathcal{R}^n$ with $n \geq m$, a measurement vector $\mathbf{x} \in \mathcal{R}^n$ and an initial parameters estimate $\mathbf{p}_0 \in \mathcal{R}^m$.

Output: A vector $\mathbf{p}^+ \in \mathcal{R}^m$ minimizing $\|\mathbf{x} - f(\mathbf{p})\|^2$.

Algorithm:

```
k := 0; ν := 2; p := p0;  
A := JTJ; εp := x - f(p); g := JTεp;  
stop := (||g||∞ ≤ ε1); μ := τ * maxi=1,...,m(Aii);  
while (not stop) and (k < kmax)  
  k := k + 1;  
  repeat  
    Solve (A + μI)δp = g;  
    if (||δp|| ≤ ε2||p||)  
      stop := true;  
    else  
      pnew := p + δp;  
      ρ := (||εp||2 - ||x - f(pnew)||2) / (δpT(μδp + g));  
      if ρ > 0  
        p = pnew;  
        A := JTJ; εp := x - f(p); g := JTεp;  
        stop := (||g||∞ ≤ ε1);  
        μ := μ * max(1/3, 1 - (2ρ - 1)3); ν := 2;  
      else  
        μ := μ * ν; ν := 2 * ν;  
      endif  
    until (ρ > 0) or (stop)  
  endwhile  
p+ := p;
```

LM算法流程^[1]

➤ 更换LM阻尼策略

- ① 采用第三章作业中的更新阻尼更新策略.
- ② 利用滑动窗口算法的性质, `marginalize`一帧后增加一帧, 问题结构变化不大。因此可利用

上一次求解的结果优化当前问题:

记录上一次求解后的阻尼因子 μ 和残差平方和 chi 值, 作为当前问题迭代初值.

- a. 若将 μ 代入当前问题, 优化后新的 chi 值变小了, 说明 μ 是一个较好的初值, 可以取阻尼因子 $\mu = 1/2 \mu$, 使LM算法更接近高斯牛顿法。
- b. 若将 μ 代入当前问题, 优化后新的 chi 值变大了, 说明 μ 是一个较差的初值, 可以取阻尼因子 $\mu = 2\mu$, 使LM算法更接近最速下降法。

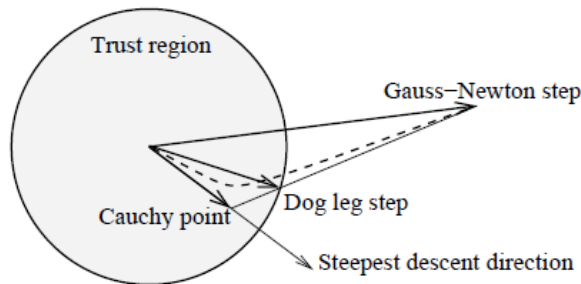
● Dog Leg算法

属于Trust Region类优化算法：

- 在以当前点为中心，半径 Δ 的区域（信赖域）内，将目标函数做二阶近似
- 分别计算最速下降法和高斯牛顿法的最优增量 δ_{sd} 和 δ_{gn} ，根据信赖域大小选择合适的增量

要点：

- ① 计算 δ_{sd} 和 δ_{gn} ；
- ② 选取合适的Dog Leg步长 δ_{dl} ；
- ③ 更新信赖域半径 Δ ；



Dog Leg算法示意图^[1]

① 计算 δ_{sd} 和 δ_{gn} ;

第三章中:

$$f(x + \Delta x) \approx f(x) + J\Delta x$$

$$F(x + \Delta x) = \frac{1}{2} \|f(x + \Delta x)\|_2^2 \approx F(x) + \Delta x^T J^T f + \frac{1}{2} \Delta x^T J^T J \Delta x \quad s.t. \|\Delta x\| \leq \Delta$$

最速下降法 $\delta_{sd} = -\alpha d$

增量方向: $d = F'(x) = (J^T f)^T$

增量步长: $\frac{dF(x - \alpha d)}{d\alpha} = 0$

$$\alpha = \frac{(J^T f)^T J^T f}{(J^T f)^T (J^T J) J^T f}$$

$$\delta_{sd} = \frac{-(J^T f)^T J^T f}{(J^T f)^T (J^T J) J^T f} \cdot (J^T f)^T$$

对应代码中 $\frac{b^T b}{b^T H b} \cdot b$


高斯牛顿法 δ_{gn}

$$J^T J \delta_{gn} = -J^T f$$


对应代码中 $Hx = b$

更好的优化策略


② 选取合适的Dog Leg步长 δ_{dl}



$$\text{若 } \|\delta_{gn}\| \leq \Delta, \|\delta_{sd}\| \in \mathbb{R} \\ \delta_{dl} = \delta_{gn}$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| > \Delta \\ \delta_{dl} = \frac{\delta_{sd}}{\|\delta_{sd}\|} \Delta$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| \leq \Delta \\ \delta_{dl} = \delta_{sd} + \alpha(\delta_{gn} - \delta_{sd})$$

② 选取合适的Dog Leg步长 $\delta_{dl}^{[1]}$

$$\delta_{dl} = \begin{cases} \kappa \delta_{sd} & 0 \leq \kappa \leq 1 \\ \delta_{sd} + (\kappa - 1)(\delta_{gn} - \delta_{sd}) & 1 \leq \kappa \leq 2 \end{cases}$$

if $\|\delta_{gn}\| \leq \Delta$

$$\kappa = 2$$

else if $\|\delta_{sd}\| \geq \Delta$

$$\kappa = \frac{\Delta}{\|\delta_{sd}\|}$$

else $\|\delta_{sd}\| < \Delta$

$$\kappa = ? \quad \|\delta_{sd} + (\kappa - 1)(\delta_{gn} - \delta_{sd})\| = \Delta$$

[1] M. L. A. Lourakis and A. A. Argyros, "Is Levenberg-Marquardt the most efficient optimization algorithm for implementing bundle adjustment?," Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1, Beijing, 2005, pp. 1526-1531 Vol. 2, doi: 10.1109/ICCV.2005.128.

③ 更新信赖域半径 $\Delta^{[2]}$

下降比 $\rho = \frac{F(\mathbf{x} + \Delta\mathbf{x}) - F(\mathbf{x})}{m_k(\mathbf{x} + \Delta\mathbf{x}) - m_k(\mathbf{x})}$

原函数值变化

信赖域内二阶近似函数值变化

if $\rho \leq 0.25$

$$\Delta = \frac{\Delta}{4}$$

➡ 近似效果不好，缩小信赖域

else $\rho \geq 0.75$

$$\Delta = \max\{\Delta, 3\|\delta_{dl}\|\}$$

➡ 近似效果较好，扩大信赖域

更快的 MakeHessian

Hessian矩阵的拼接过程非常适合并行计算

方法:

① OpenMP 最便捷，相关博客也最多。

<http://supercomputingblog.com/openmp/openmp-tutorial-the-basics/>

② SSE Instruction Set

<http://supercomputingblog.com/optimization/getting-started-with-sse-programming/>

③ Nvidia CUDA 较复杂，可参考CUDA官方文档

<https://cuda-tutorial.readthedocs.io/en/latest/tutorials/tutorial01/>

记录矩阵拼接函数调用**总次数**和拼接部分的**总时间**，对比平均值



深蓝学院
shenlanxueyuan.com

祝大家牛年快乐，万事胜意！

